Aprendizado de Máquina via Algoritmo Random Forest

Estudo de caso: redes sociais derrubam a nossa produtividade?

Disciplina: Inteligência Artificial

Alunos

Antônio Rodrigo Lima de Andrade Tenório (23210707)

Bruno Gomes de Barros Filho (21111360)

1. Introdução à Inteligência Artificial

O que é Inteligência Artificial?

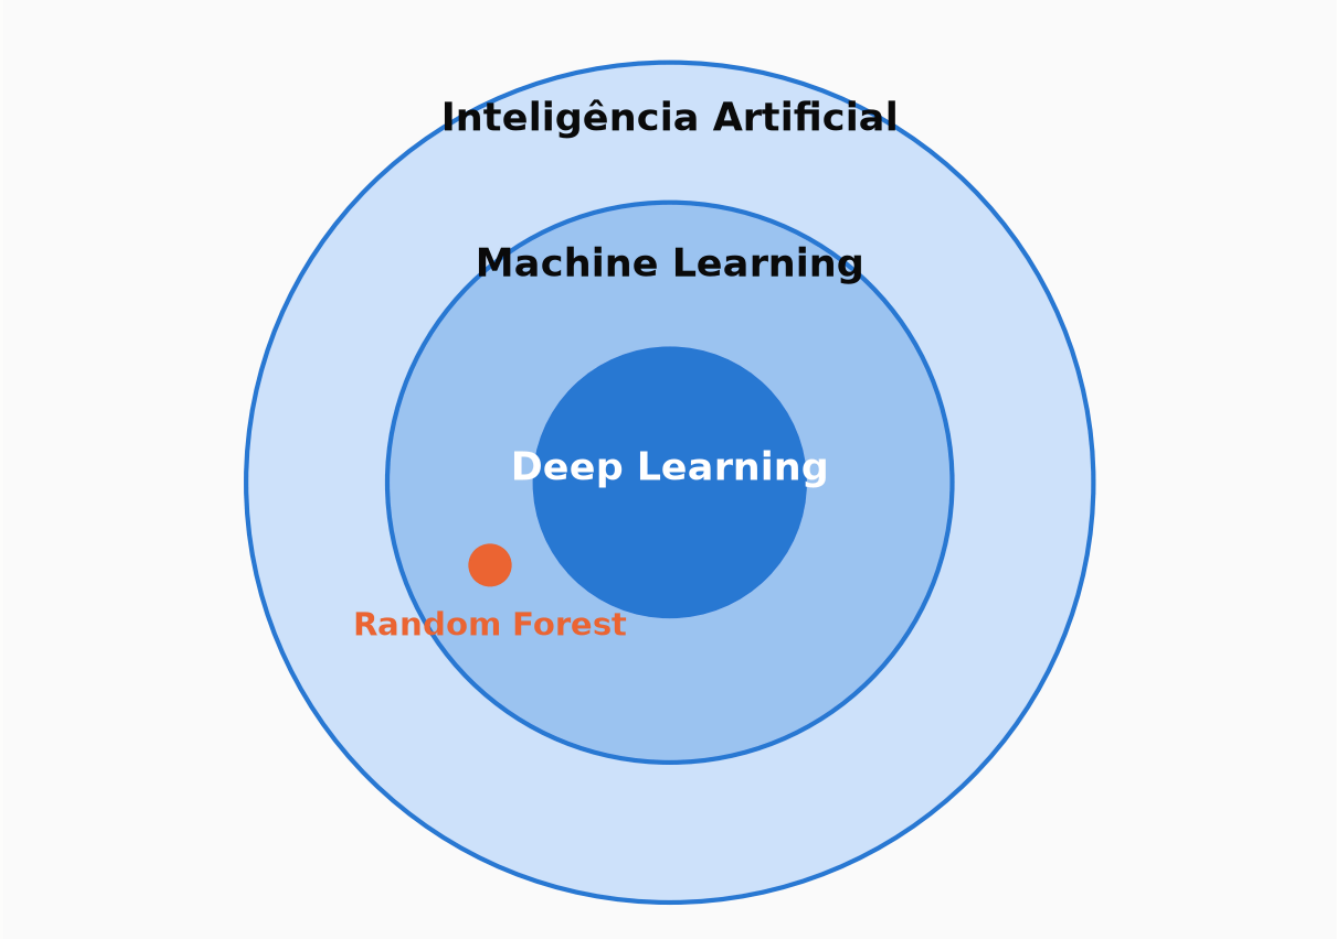
- Área da computação que cria sistemas capazes de realizar tarefas que **normalmente exigiriam inteligência humana**
- **Reconhecer:** rostos, voz, objetos
- **Entender:** textos e perguntas
- **Decidir:** rotas, recomendações
- **Prever:** clima, demanda, comportamento

> Você usa IA várias vezes por dia: o feed da sua rede social é organizado por uma.

Uma linha do tempo rápida

- **1950:** Alan Turing pergunta *"As máquinas podem pensar?"*
- **1956:** o termo *Inteligência Artificial* é cunhado na conferência de Dartmouth
- **Anos 1980–90:** sistemas especialistas (regras escritas à mão) e o crescimento do Machine Learning
- **2001:** Leo Breiman publica o **Random Forest**, o algoritmo de hoje
- **Hoje:** assistentes de IA, carros autônomos, diagnóstico por imagem

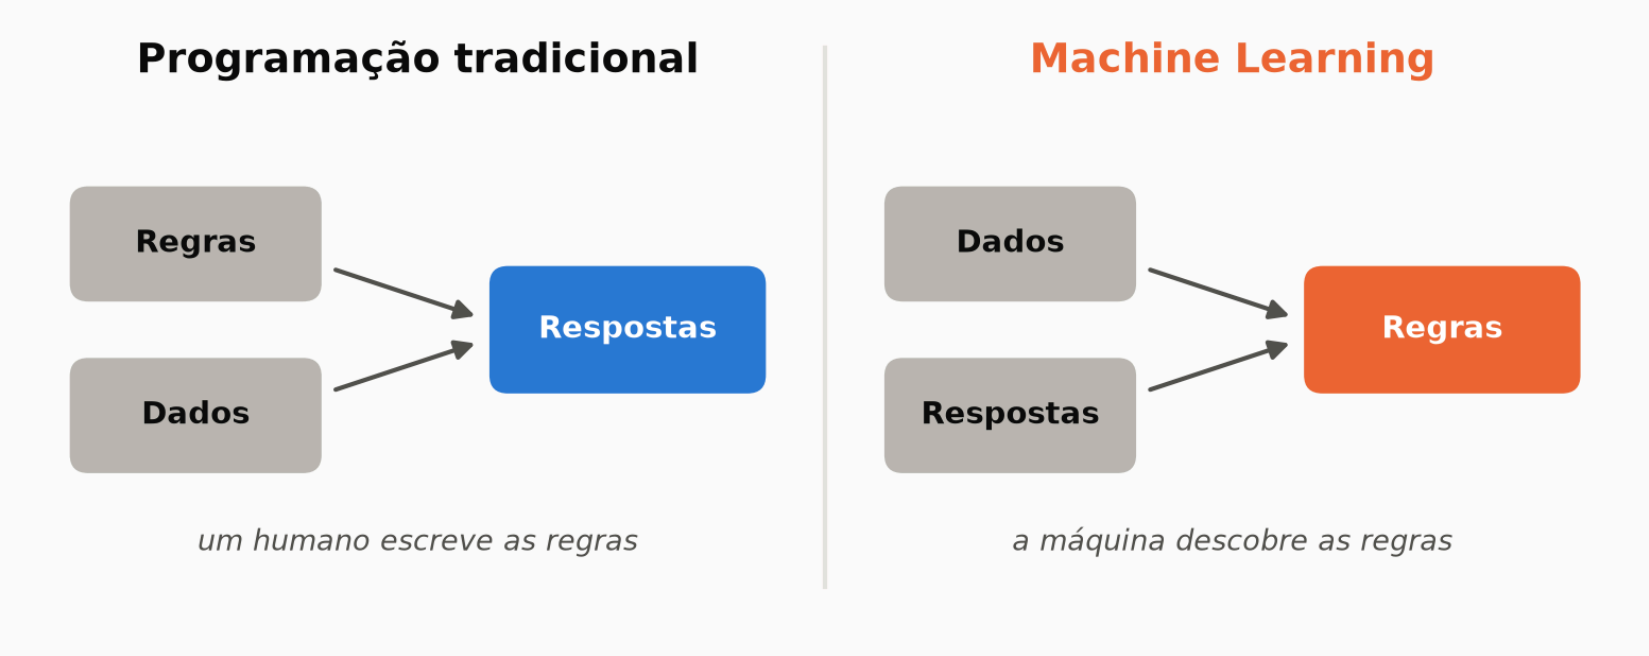
Onde entra o Machine Learning?



2. Mergulho em Machine Learning

Como as máquinas aprendem com dados

Programar vs ensinar



- Tradicional: *"SE usa mais de 5 h de redes, ENTÃO é pouco produtivo"*
- ML: *"Aqui estão 22 mil pessoas e a produtividade de cada uma. Descubra o que importa."*

Features e alvo

Idade	Redes sociais	Notificações	Sono	Satisfação	...	Produtividade
32	4,0 h	60	7 h	6	...	5,8
45	1,5 h	52	6 h	3	...	3,1
27	6,2 h	71	8 h	8	...	7,4

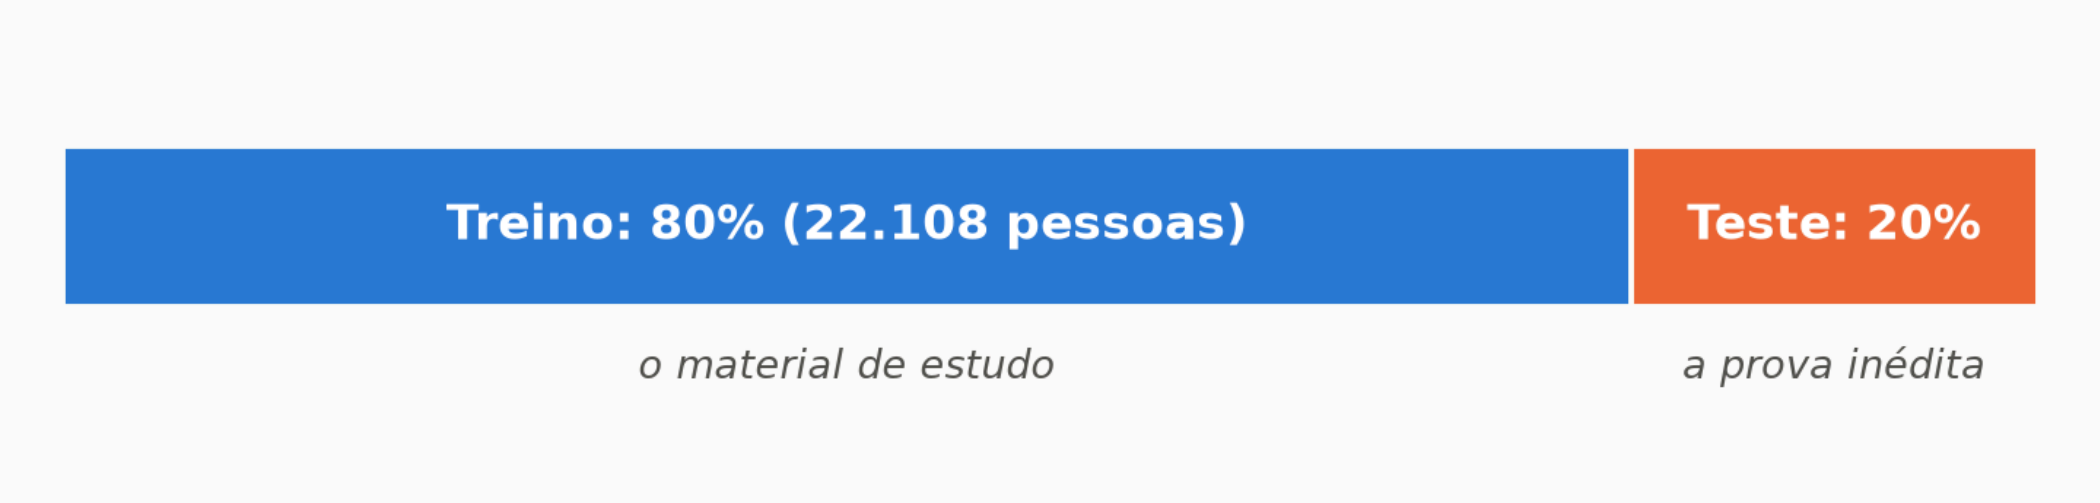
- **Features:** o que sabemos sobre cada pessoa
- **Alvo:** o que queremos prever
- O algoritmo procura **padrões** que ligam as features ao alvo em milhares de exemplos

Que tipo de pergunta estamos fazendo?

Aprendizado supervisionado: temos as respostas certas para aprender

- **Classificação:** prever uma categoria. *"Esse e-mail é spam ou não?"*
- **Regressão:** prever um número. *"Qual a produtividade desta pessoa, de 0 a 10?"*
- **Nosso caso: regressão.** O alvo é um número contínuo; dividir em "baixa / média / alta" jogaria informação fora

Treino e teste: a prova com questões inéditas



- O modelo estuda só o treino e é avaliado em pessoas que **nunca viu**
- **Overfitting = decorar a matéria:** tira 10 nos exercícios e vai mal na prova

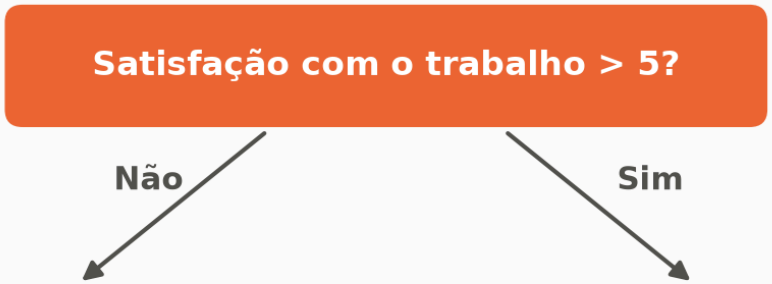
3. Random Forest, passo a passo

Da árvore única à floresta

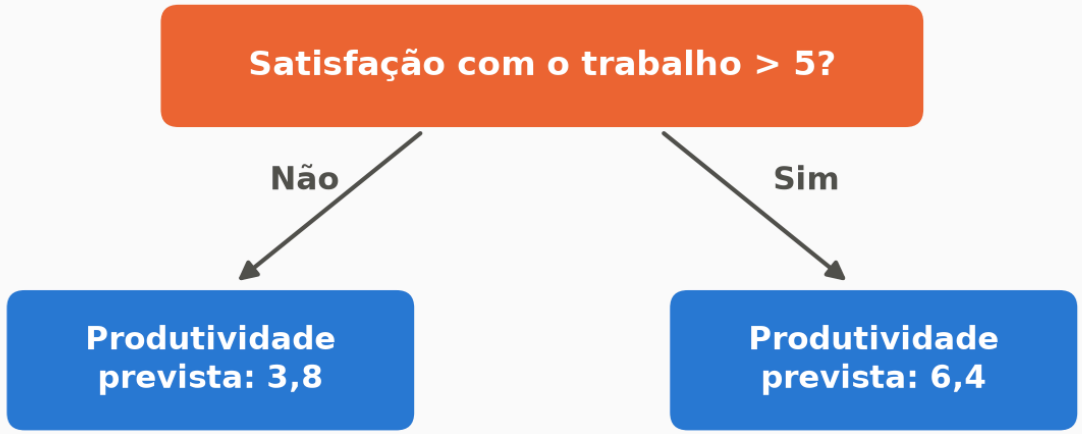
Peça 1: uma Árvore de Decisão



Peça 1: uma Árvore de Decisão

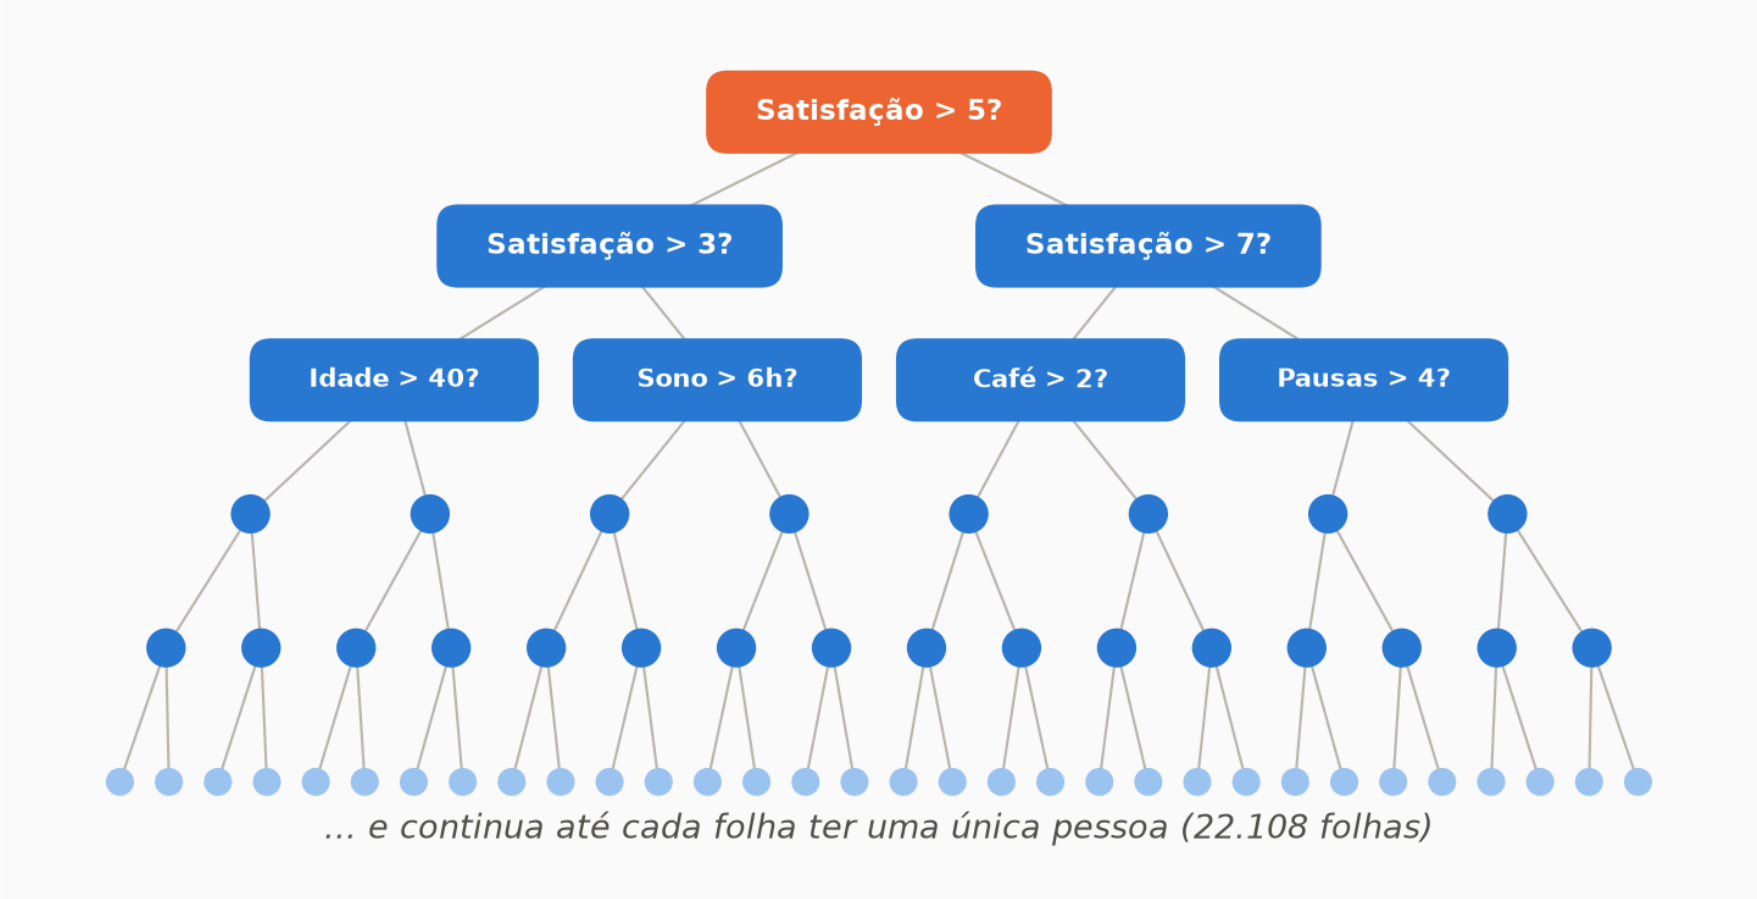


Peça 1: uma Árvore de Decisão



primeira pergunta escolhida pelo algoritmo nos nossos dados

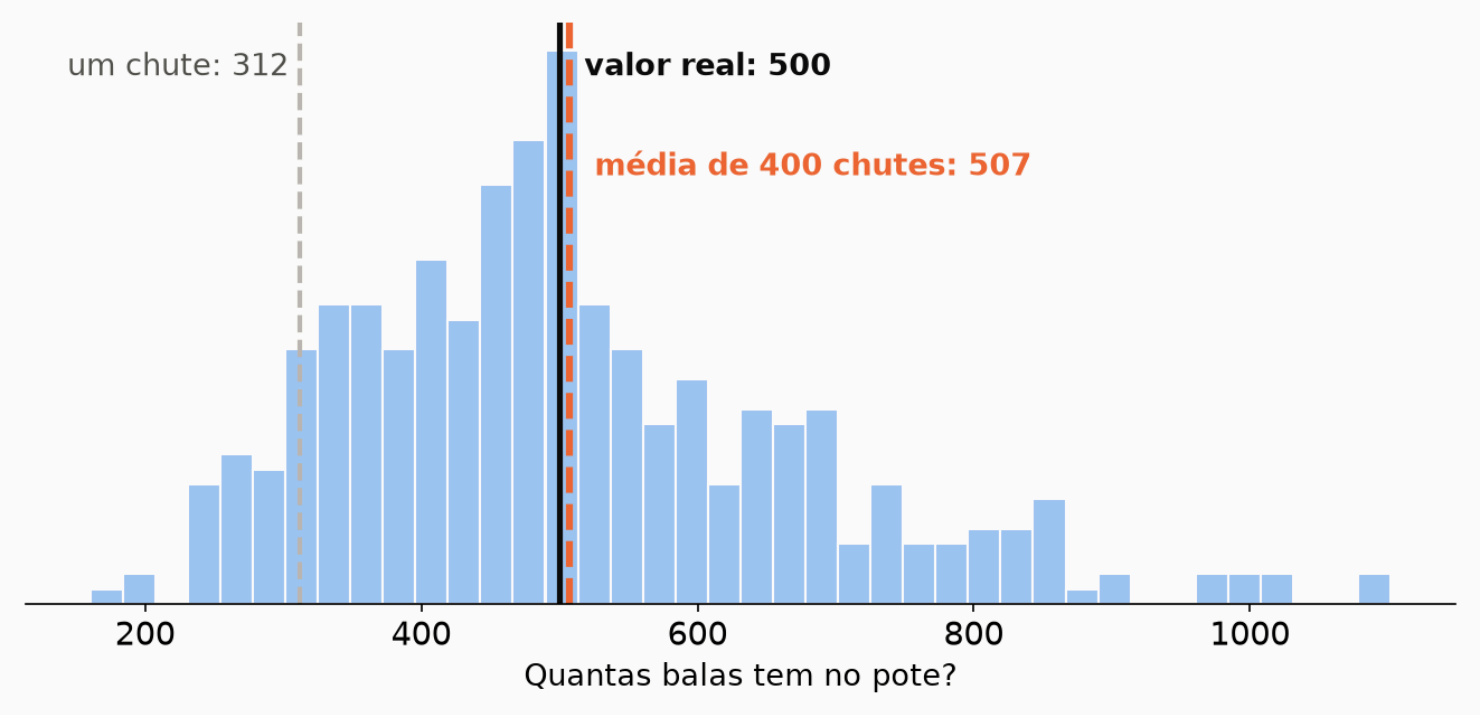
A árvore cresce...



Peça 2: o problema da árvore única

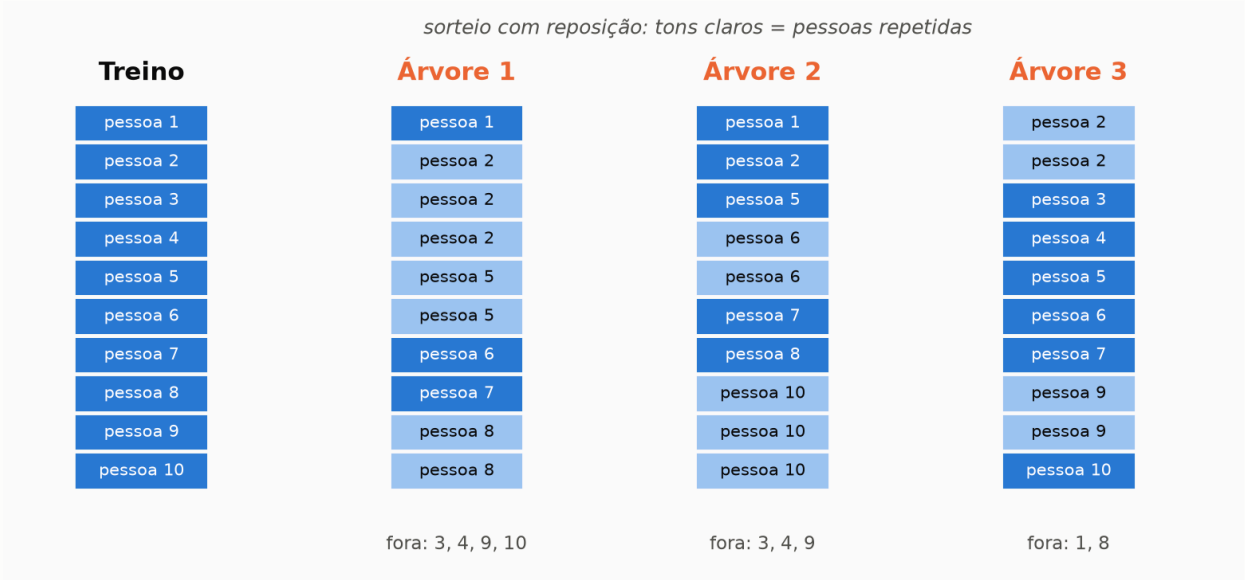
- R^2 no treino: **1,00**. *Acertou 100% do que estudou.*
- R^2 em dados novos: **0,41**. *Foi mal na prova.*
- Uma árvore sozinha **decora**, e é instável: mudar poucos dados muda a árvore inteira

A ideia: sabedoria das multidões



- Um chute individual erra feio; **a média de centenas de chutes chega perto do valor real**
- E se, em vez de uma árvore, usarmos **centenas**?

Ingrediente 1: cada árvore estuda uma amostra diferente



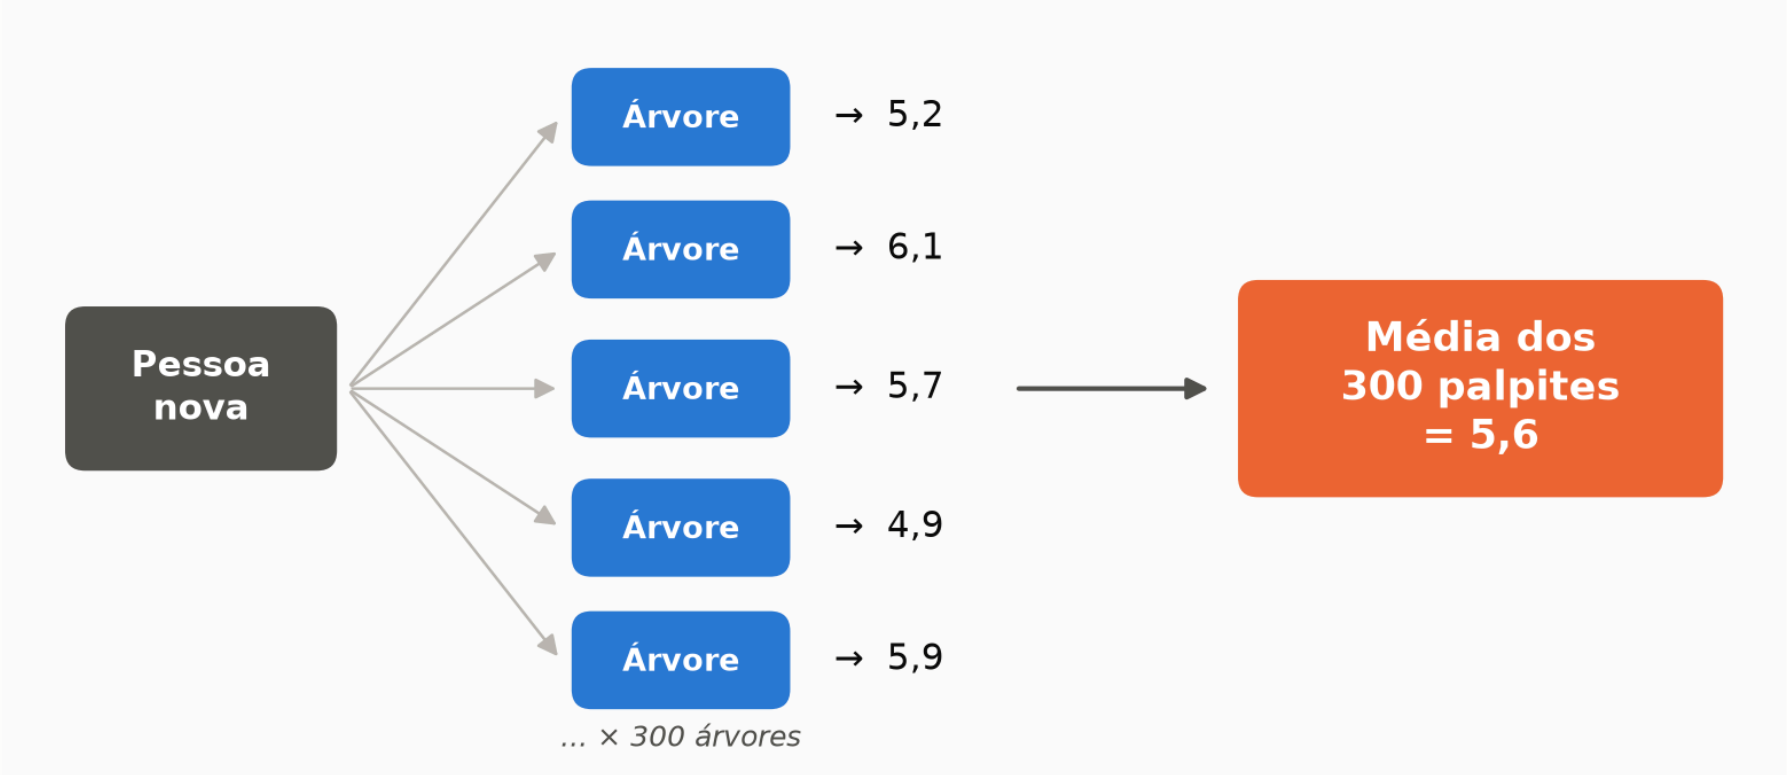
- **Bootstrap:** sorteio de linhas *com reposição*. Algumas pessoas se repetem, outras ficam de fora
- Os ~37% que ficam de fora viram uma **prova surpresa gratuita** (*out-of-bag*)

Ingrediente 2: cada pergunta vê só parte das variáveis



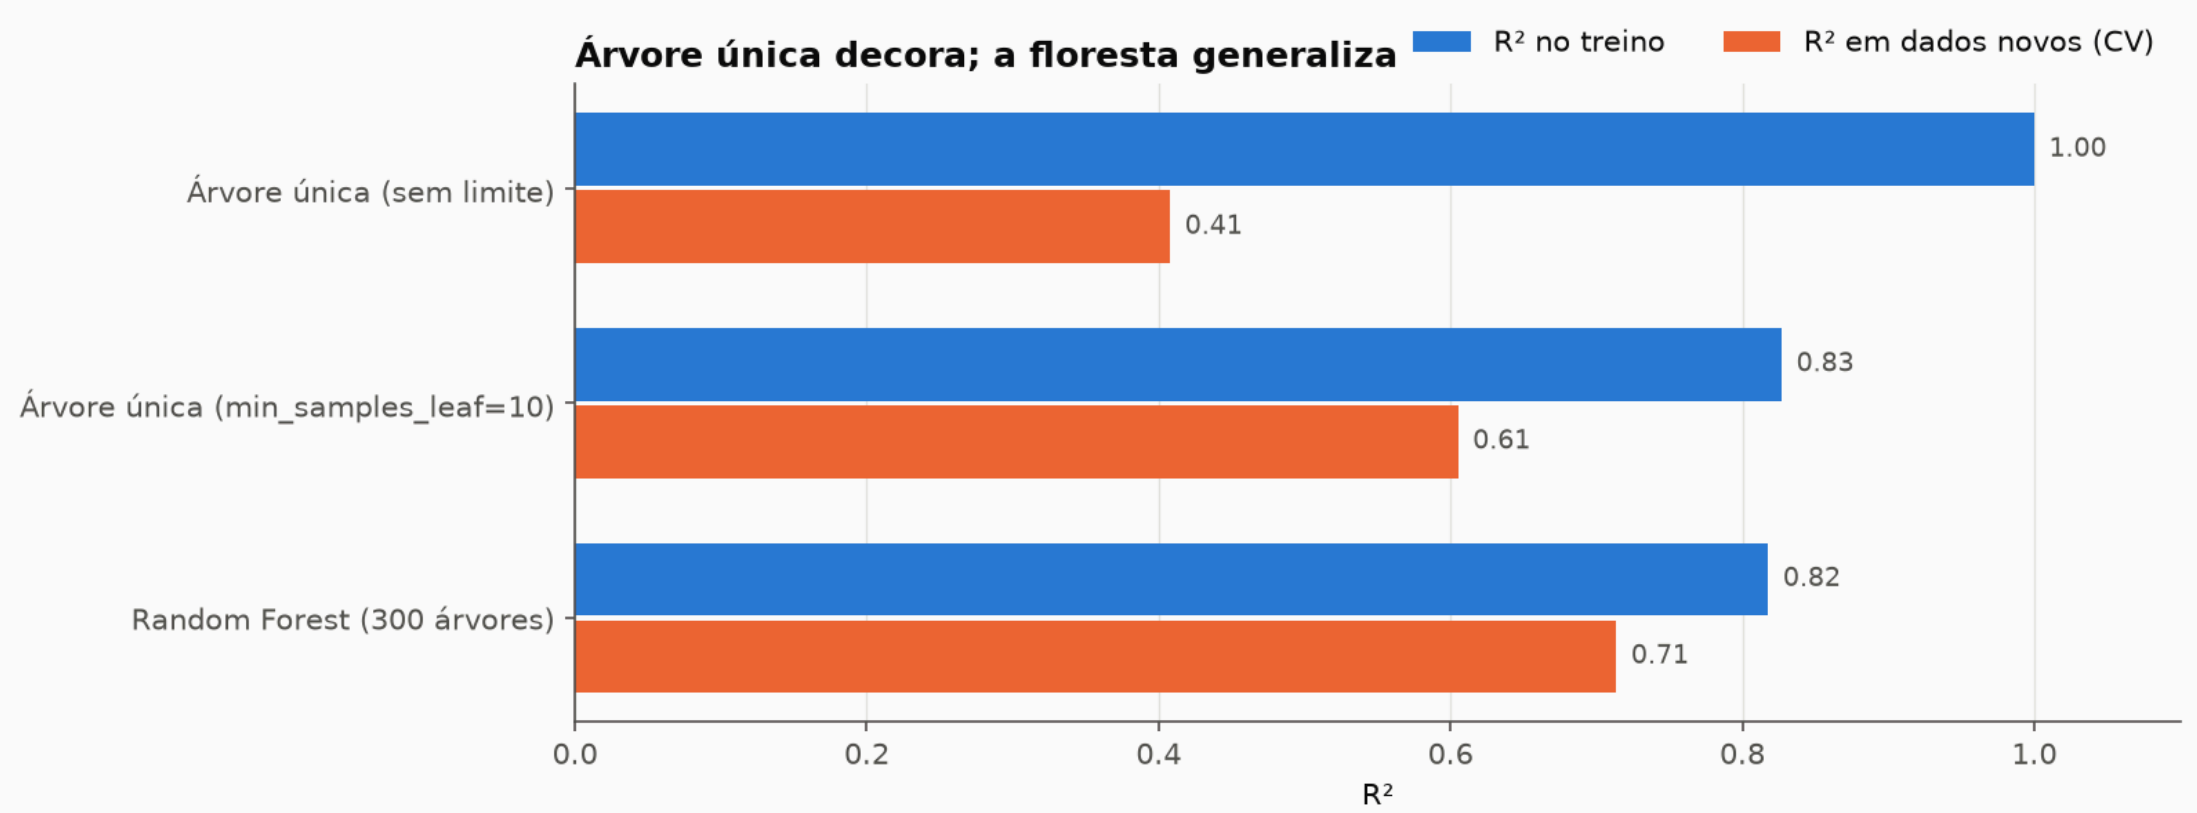
- Em cada pergunta, um **novo sorteio** de variáveis (no projeto: 50% delas)
- Árvores **diferentes entre si** erram de jeitos diferentes. É o **"Random"** do nome

A floresta: o consenso



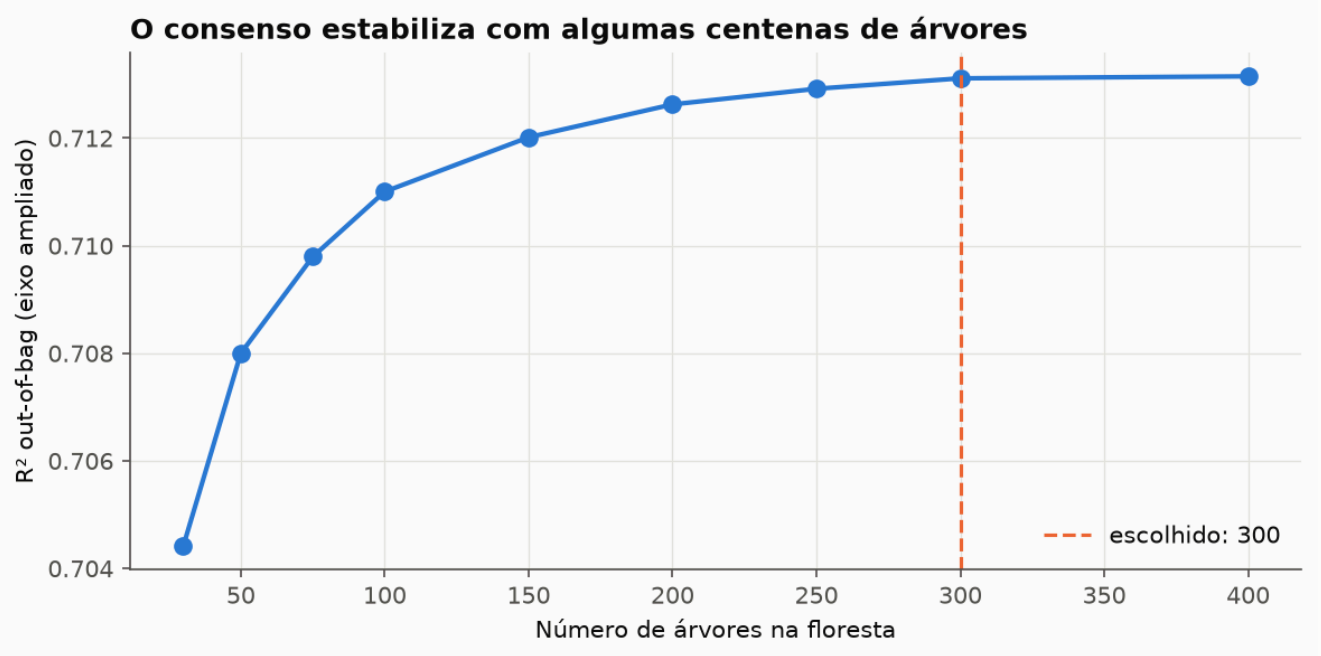
- Cada uma das 300 árvores dá um palpite; a previsão final é a média

Árvore única vs floresta



- Com os mesmos dados, o acerto em pessoas novas foi de **0,41 para 0,71**

Quantas árvores são suficientes?



- Sobe rápido até ~100 e **estabiliza** a partir de ~250 (eixo vertical ampliado)
- Escolhemos **300 árvores**, 50% das variáveis por pergunta e mínimo de 10 pessoas por folha

4. O Projeto

Redes Sociais vs Produtividade

Redes sociais derrubam a nossa produtividade?

- O senso comum diz que **sim**
- Vamos perguntar aos dados e deixar o **Random Forest** decidir o que importa

O dataset

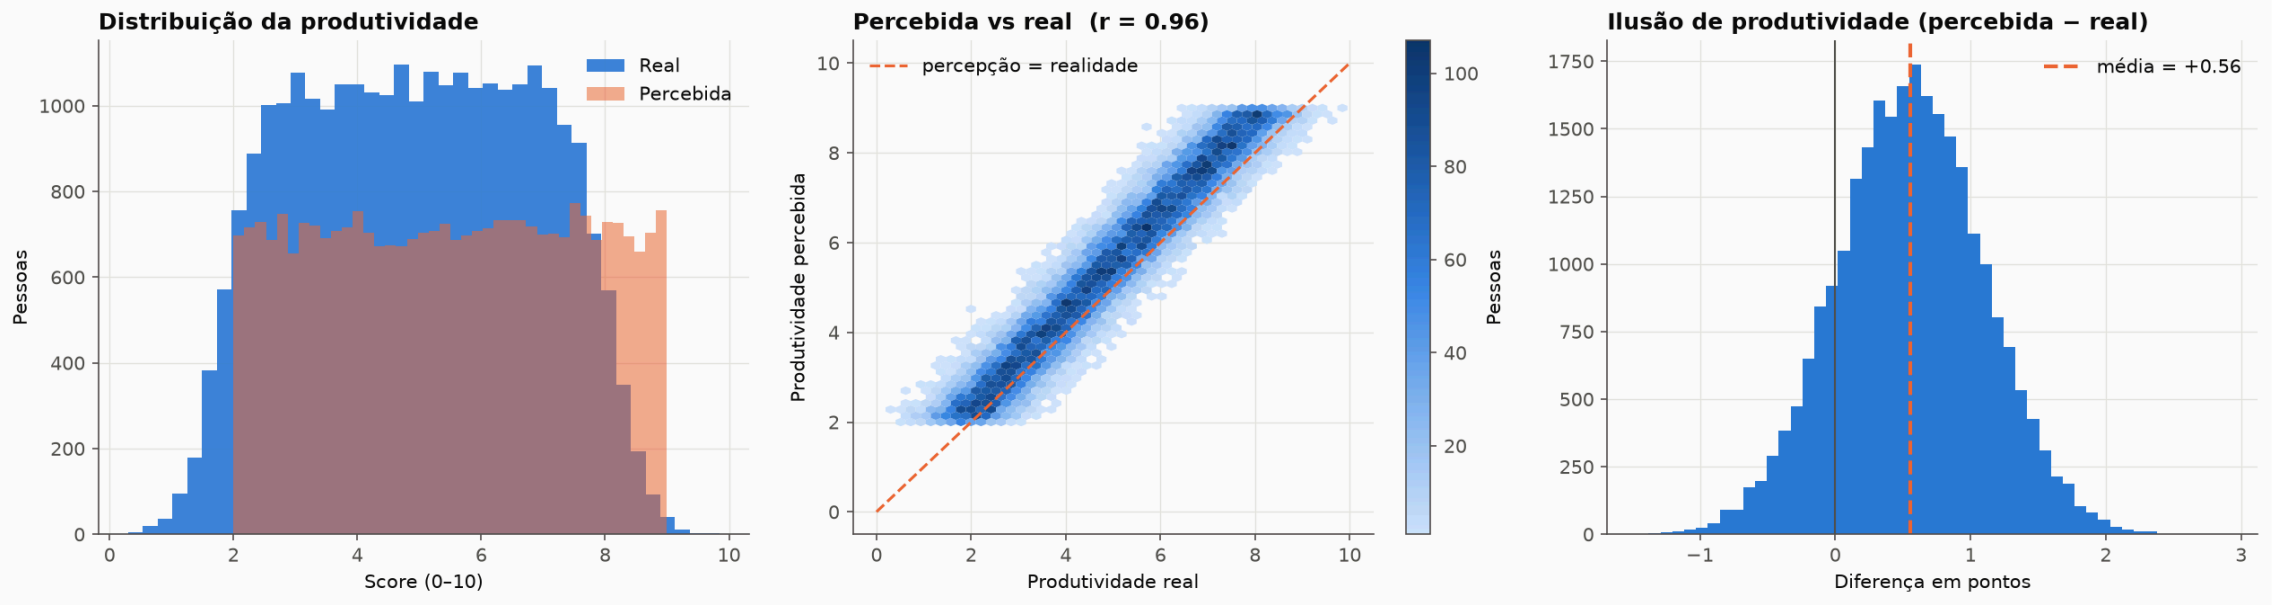
- **30.000 pessoas** e **19 informações** sobre cada uma
- **Perfil:** idade, gênero, área de atuação
- **Hábitos digitais:** horas em redes sociais, rede favorita (TikTok, Instagram, Facebook, Twitter, Telegram), notificações, tela antes de dormir
- **Rotina e bem-estar:** horas de trabalho, pausas, café, sono, estresse, burnout, satisfação com o trabalho
- **Alvo:** produtividade real, de 0 a 10

O pipeline



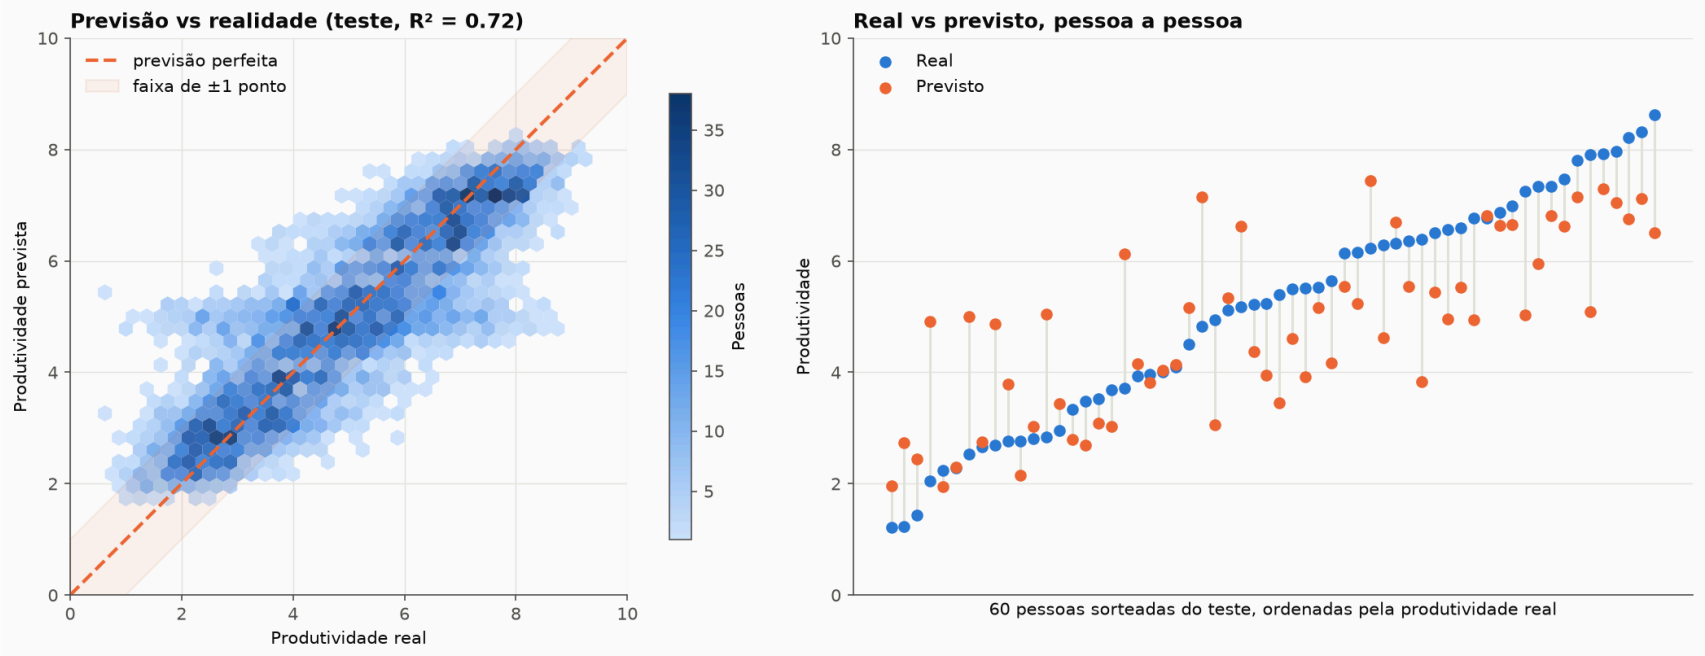
- Cada fase está em um **notebook separado** no repositório
- Antes de treinar: tratamento de **valores nulos** e conversão de categorias em números

Primeira descoberta: a ilusão de produtividade



- **85% das pessoas se acham mais produtivas do que são**, em média +0,56 ponto
- Por isso **não usamos** a produtividade percebida como entrada: seria prever a resposta usando a própria resposta (*data leakage*)

O modelo funciona?

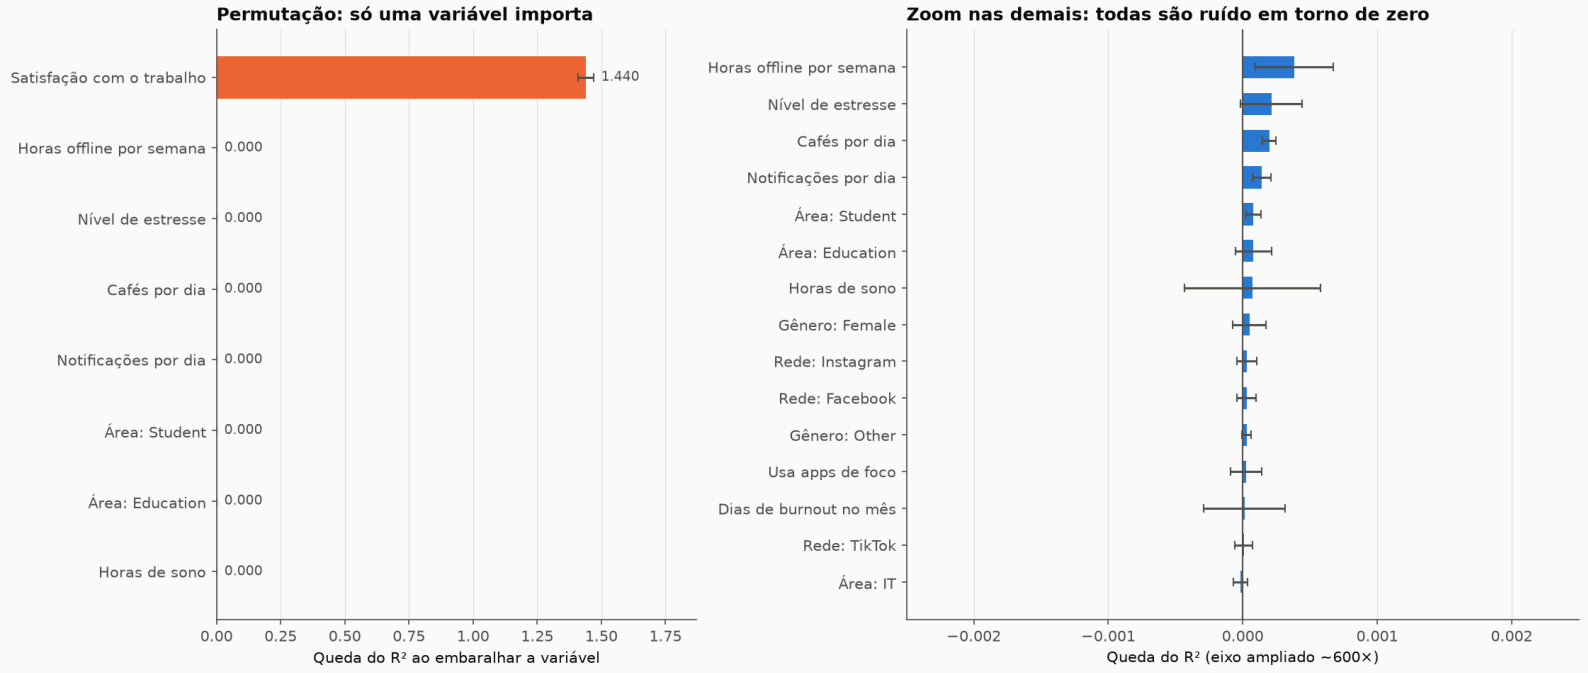


- **R^2 = 0,72 · erro médio = 0,78 ponto · 72%** das previsões a até 1 ponto do real
- Testado em **5.527 pessoas** que o modelo nunca viu (chutar a média erraria 1,6 ponto)

5. Descobertas

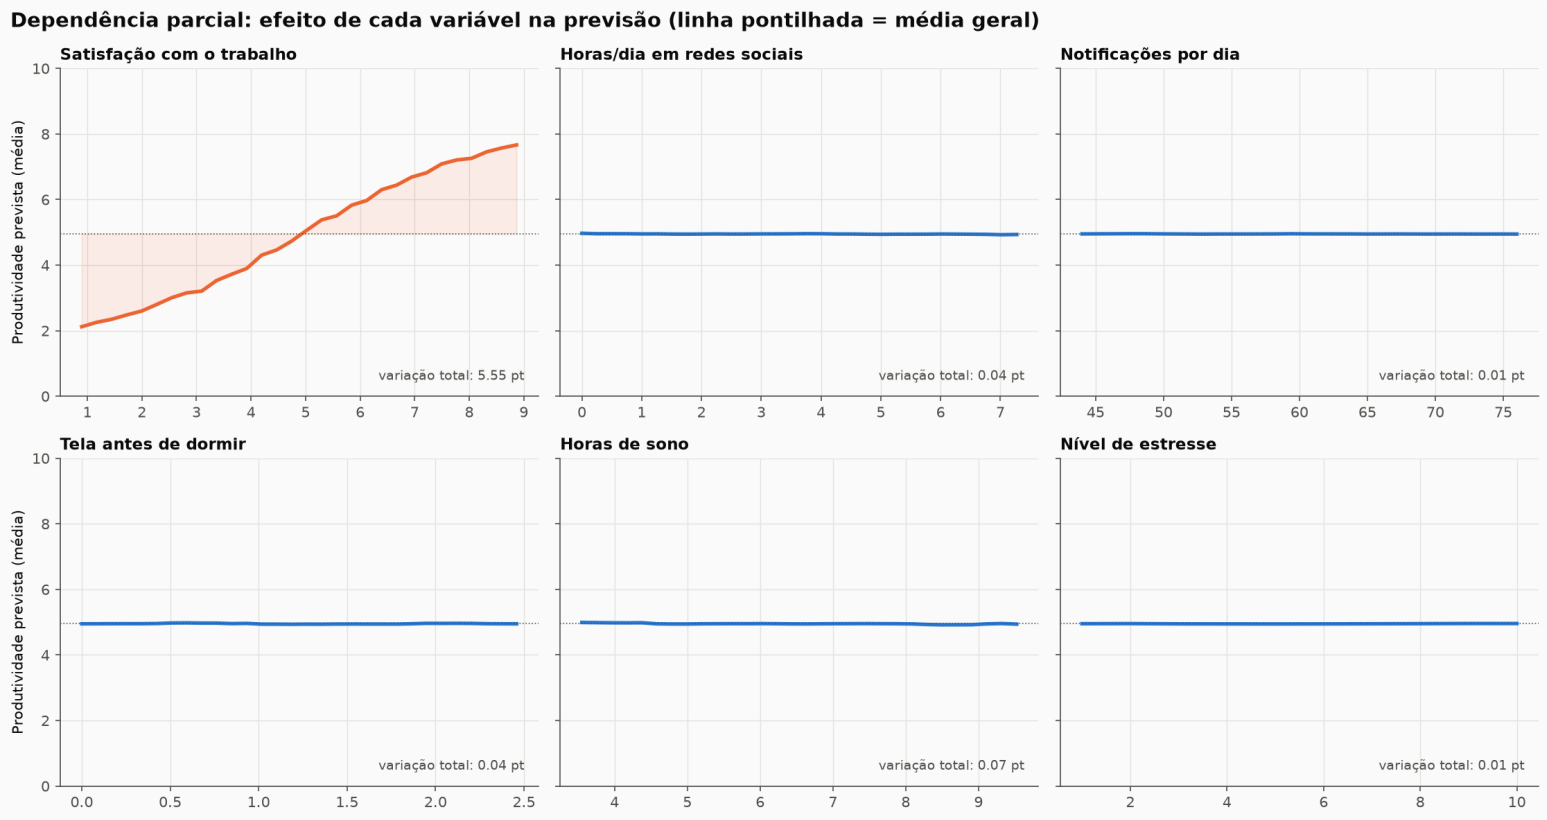
O que o Random Forest aprendeu

O que o modelo usa para prever?



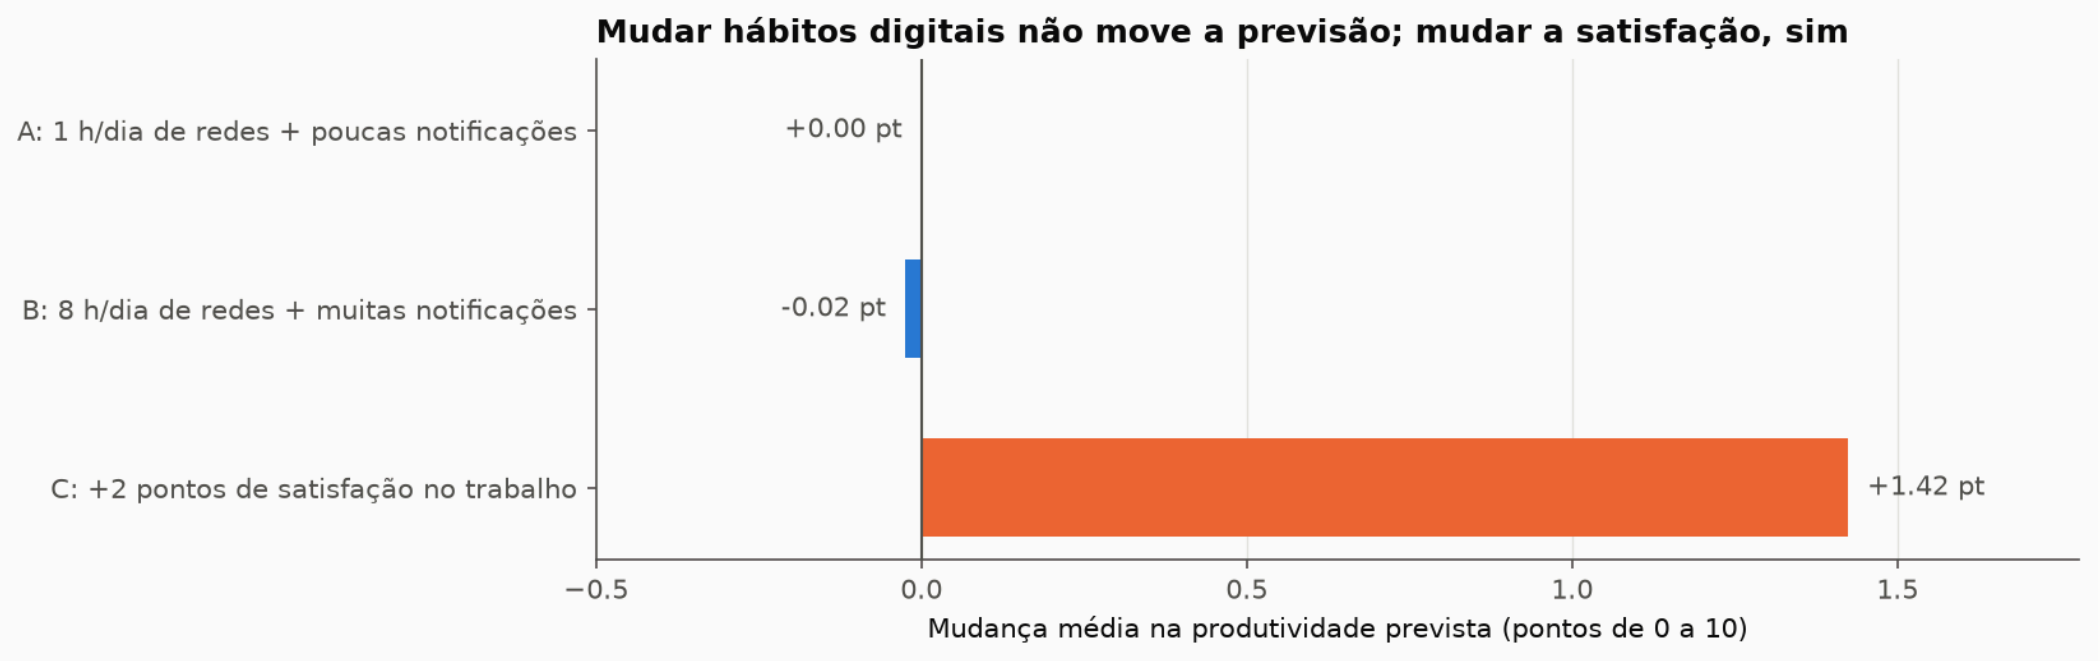
- *"Se eu embaralhar esta informação, o modelo piora quanto?"*
- Entre 28 variáveis, encontrou **sozinho** a única que importa: **satisfação com o trabalho**

E as redes sociais?



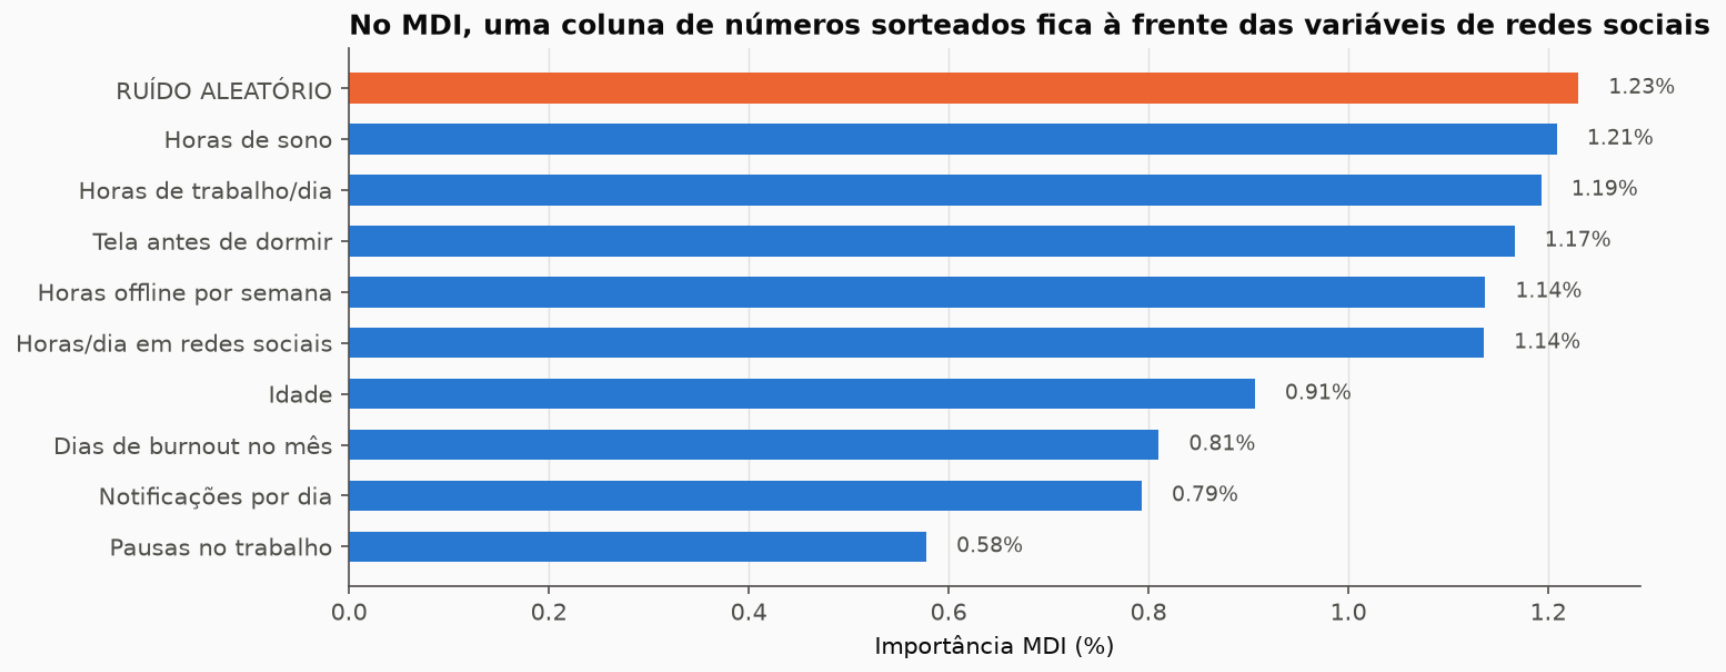
- De 0 a 7 h/dia de redes: a previsão muda **0,04 ponto**. Satisfação: **5,5 pontos**

Simulação: "e se...?"



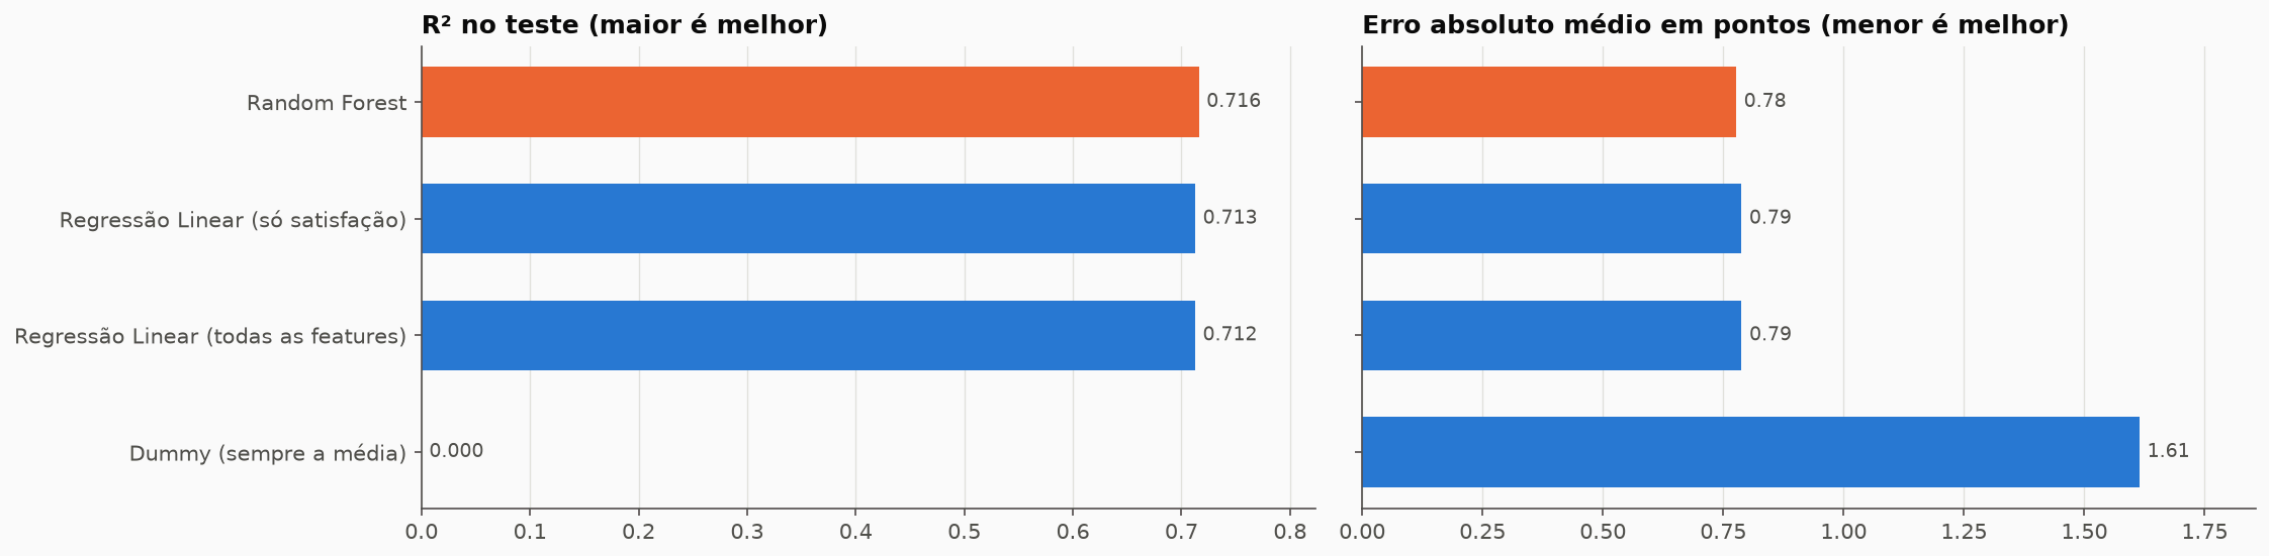
- *E se todos usassem só 1 h/dia?* → **0,00 ponto**
- *E se todos usassem 8 h/dia, com muitas notificações?* → **−0,02 ponto**
- *E se a satisfação de todos subisse 2 pontos?* → **+1,42 ponto**

Plot twist: a Feature Importance pode mentir



- Adicionamos uma coluna de **números sorteados ao acaso**, e ela ficou em **2º lugar**, à frente das redes sociais
- A importância padrão (MDI) premia até ruído. Para concluir algo, use **permutação nos dados de teste**

Um modelo simples empata



- Regressão linear usando **só a satisfação**: R^2 0,713 · Random Forest com 28 variáveis: R^2 0,716
- Não havia padrões complexos escondidos: **o sinal estava em uma única variável**

Então redes sociais não fazem mal?

- **Dados sintéticos:** as variáveis não têm relação nenhuma entre si (nem sono com estresse), algo improvável na vida real
- **Correlação não é causalidade:** o modelo aprende associações, não causas
- **A pesquisa real é mais nuançada:** efeitos negativos aparecem mais ligados a **interrupções** e **uso compulsivo** do que ao tempo total de tela

> A conclusão vale para **estes dados**, não necessariamente para a vida de vocês.

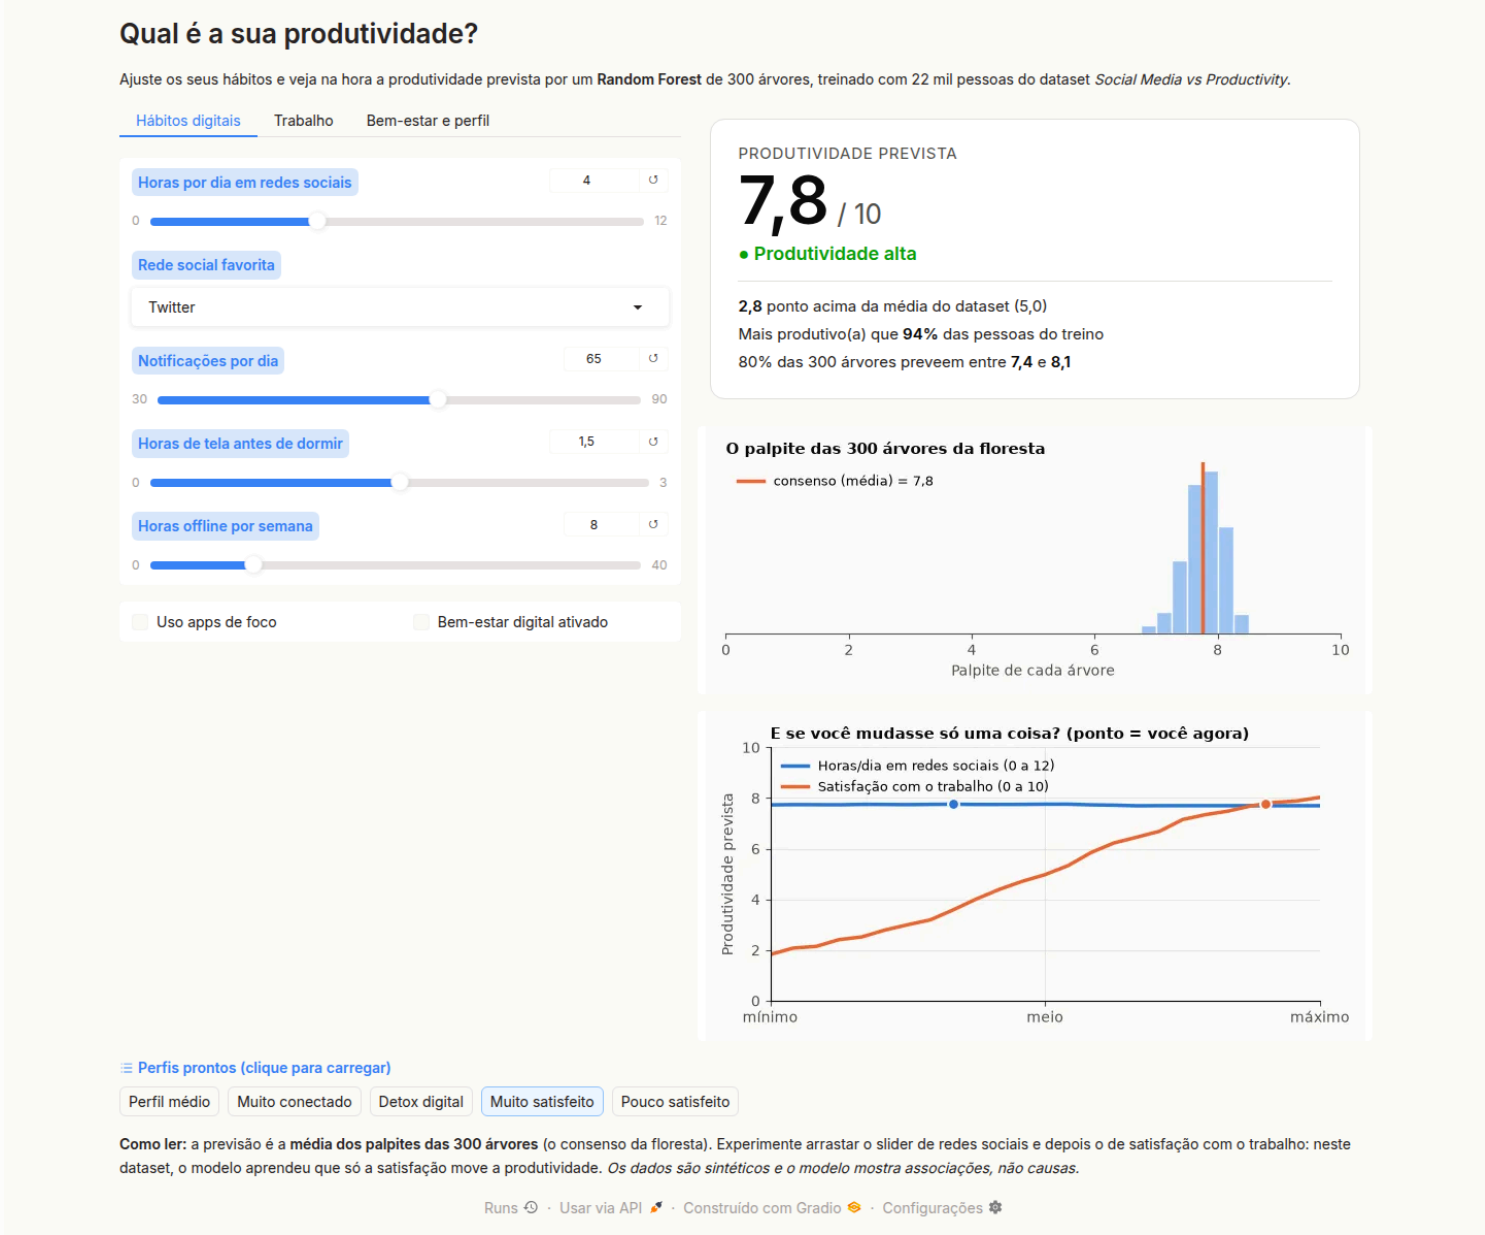
O que aprendemos sobre Machine Learning

1. O modelo **só aprende o que está nos dados**
2. Sempre compare com um **baseline simples**
3. Desconfie da Feature Importance padrão; use **permutação**
4. Um resultado "nulo" **também é um resultado**

6. Agora é com vocês

Qual seria a SUA produtividade?

- Uma **interface interativa** feita com Gradio
- Sliders e menus para os seus hábitos
- O modelo responde **na hora** e mostra o palpite de **cada uma das 300 árvores**
- **Demonstração ao vivo**



Obrigado!

Perguntas?

Random Forest: muitas árvores diferentes, uma decisão melhor.

Antônio Rodrigo Lima de Andrade Tenório · Bruno Gomes de Barros Filho

Repositório: github.com/rodrigololr/ubiquitous-invention